Modelo algorítmico de trading basado en pronósticos de precios de activos financieros mediante modelos de series de tiempo ARIMA

Jerónimo Gil Giraldo
Sofía Tobón Arismendy
José Julián Vásquez Jiménez
Escuela de Ciencias Aplicadas e Ingeniería
Universidad EAFIT

23 de octubre de 2026

1. Introducción

Los mercados financieros son fundamentales para la asignación de recursos y la inversión. Por ello, anticipar el comportamiento futuro de los activos se ha vuelto clave en las finanzas cuantitativas, ya que los pronósticos de precios ayudan a los inversionistas a anticipar movimientos y tomar decisiones. El pronóstico de precios e índices bursátiles puede brindar información sobre posibles movimientos del mercado y servir como apoyo para la toma de decisiones de inversionistas y operadores financieros [1]. Así, el análisis de series temporales resulta relevante, incluso algunas investigaciones recientes han encontrado que la información contenida en el comportamiento histórico de los precios puede presentar capacidad predictiva sobre los rendimientos futuros, lo que evidencia el interés de desarrollar metodologías cuantitativas orientadas al pronóstico financiero [2].

Sin embargo, el pronóstico de los precios de los activos financieros es un desafío debido a las características de las series de tiempo bursátiles. Estas series pueden presentar comportamientos no lineales y no estacionarios, además de altos niveles de ruido e incertidumbre, lo que hace más difícil identificar patrones estables a partir de la información histórica. Además, la dinámica de los mercados puede variar a lo largo del tiempo haciendo que las relaciones observadas en un periodo determinado no necesariamente se mantengan en periodos posteriores.Debido a estas características se han desarrollado y aplicado diferentes metodologías de pronóstico que permiten aprovechar la información temporal disponible y modelar la complejidad en los datos financieros [3].

Distintos autores muestran el uso de modelos predictivos y técnicas de aprendizaje automático en estrategias de trading, y tambien resaltan la importancia de evaluar dichas

estrategias mediante procedimientos de backtesting sobre datos históricos y en diferentes condiciones de mercado [5, 6]. En este sentido la capacidad predictiva de un modelo no implica necesariamente un buen desempeño financiero de una estrategia de inversión, ya que los pronósticos deben convertirse en reglas de decisión que indiquen cuándo comprar, vender o mantener una posición en el mercado. Por lo tanto la evaluación de un sistema de trading debe considerar tanto la calidad de los pronósticos como el comportamiento financiero de las decisiones tomadas.

En este trabajo se propone abordar esta problemática mediante el diseño de una estrategia algorítmica de trading basada en los pronósticos de precios de activos financieros obtenidos a partir de un modelo ARIMA soportado por resultados estadísticamente significativos. En la literatura, los modelos autorregresivos se han aplicado desde diversas perspectivas, por un lado se ha evaluado su capacidad predictiva frente a metodologías heurísticas tradicionales como los promedios móviles simples (SMA) en mercados de alta volatilidad [7], por otro lado, se han explorado extensiones que condicionan la ejecución de las señales ARIMA al perfil de riesgo y la personalidad del inversor [8]. También, es frecuente encontrar arquitecturas híbridas más complejas, como la combinación ARIMA-SGARCH diseñadas para modelar simultáneamente la media y la varianza condicional en índices bursátiles como el S&P 500 [9]. Sin embargo, a pesar de la gran cantidad de estudios enfocados en comparar la precisión predictiva o la rentabilidad de modelos híbridos, existe un vacío en la literatura respecto a la relación directa entre la precisión estadística de los pronósticos de un modelo ARIMA puro y la construcción de reglas sistemáticas de trading sustentadas exclusivamente en dichos pronósticos. A partir de esta brecha, surge la siguiente pregunta de investigación ¿En qué medida los pronósticos generados mediante un modelo ARIMA pueden utilizarse en el desarrollo de una estrategia algorítmica de trading y cuál es el desempeño financiero de dicha estrategia al evaluarse mediante procedimientos de backtesting sobre datos históricos?

Para realizar el análisis, se seleccionarán cinco índices bursátiles asociados al mercado NASDAQ y cinco acciones de empresas reconocidas negociadas en dicho mercado. Los índices que se utilizarán serán el S&P 500, NASDAQ-100, Dow Jones Industrial Average, NASDAQ Biotechnology Index y NASDAQ Bank Index. Por otro lado, las acciones seleccionadas serán Apple, Microsoft, Amazon, Alphabet y NVIDIA. La selección de estos activos busca trabajar con instrumentos conocidos y que cuenten con suficiente información histórica para realizar el análisis y los pronósticos mediante el modelo ARIMA. Inicialmente, se realizará la selección, preparación y exploración de datos históricos de los activos financieros objeto de estudio, seguido del ajuste y validación del modelo ARIMA para generar pronósticos y establecer una línea base de desempeño predictivo mediante métricas de error. Posteriormente, se diseñarán reglas sistemáticas para generar señales de compra, venta y permanencia a partir de los pronósticos obtenidos, buscando establecer una relación entre el modelo estadístico y la toma de decisiones de inversión. Finalmente, se implementará un proceso de backtesting para evaluar el comportamiento de la estrategia sobre datos históricos utilizando métricas de rentabilidad y riesgo.

2. Métodos

En este trabajo se desarrollará una metodología cuantitativa basada en el análisis de series de tiempo y la evaluación de una estrategia algorítmica de trading. Se implementará el postulado matemático del modelo ARIMA para representar la dinámica temporal de los precios y sustentar su estimación. Para cada activo se recopilarán datos históricos entre el 01-01-2016 y el 01-10-2026, los cuales se organizarán cronológicamente y se revisarán para identificar valores faltantes, duplicados e inconsistencias. Posteriormente, las observaciones se dividirán secuencialmente en un 80 % para entrenamiento y un 20 % para evaluación. Durante esta última etapa se utilizará la técnica de validación de avance paso a paso (*walk-forward validation*), mediante la cual se generará un pronóstico a un periodo y se incorporará cada nuevo valor observado antes de realizar el siguiente pronóstico, evitando el sesgo de anticipación.

Para cada activo se ajustará un modelo ARIMA(p, d, q) siguiendo el enfoque de Box-Jenkins[4]. El parámetro d se determinará mediante el análisis de estacionariedad y la prueba aumentada de Dickey-Fuller (ADF), mientras que los parámetros p y q se seleccionarán considerando las funciones de autocorrelación (ACF) y autocorrelación parcial (PACF), así como la significancia estadistica de sus parámetros y los criterios AIC (Criterio de Información de Akaike) y BIC (Criterio de Información Bayesiano), priorizando la minimización del AIC en un modelo estadisticamente significativo. Adicionalmente, se analizarán los residuos mediante la prueba de Ljung-Box para los rezagos 10 y 20, con el fin de verificar su compatibilidad con el comportamiento de ruido blanco.

La precisión de los modelos se evaluará comparando los precios pronosticados con los observados mediante las métricas RMSE (Raiz del error cuadrático medio), MAE (Error absoluto medio)y el MAPE (Error porcentual absoluto medio). Posteriormente, los pronósticos se utilizarán para establecer reglas sistemáticas de compra, venta o mantenimiento de la posición, aplicadas a los activos seleccionados para el *backtesting*: Apple, NASDAQ 100, Dow Jones y S&P 500. Finalmente, se simulará la estrategia con datos históricos, registrando las operaciones y calculando métricas de rentabilidad y riesgo para evaluar su desempeño bajo las condiciones previamente establecidas.

2.1. Postulado matemático

Para el pronóstico de los precios de los activos financieros se empleará un modelo ARIMA (p, d, q), debido a que este permite representar la dependencia temporal de una serie mediante una combinación de componentes autorregresivos y de medias móviles, incorporando además un procedimiento de diferenciación para tratar posibles comportamientos no estacionarios de la serie de precios.

Sea Y_t el precio observado del activo financiero en el instante t, con $t = 1, \ldots, T$.

El modelo se formulará mediante el operador de rezago denotado por B, definido como

$$BY_t = Y_{t-1}, \tag{1}$$

de modo que, en general,

$$B^k Y_t = Y_{t-k}. \tag{2}$$

La componente integrada del modelo se obtiene mediante la diferenciación de la serie de precios. Una primera diferencia se expresa como

$$\Delta Y_t = (1 - B)Y_t = Y_t - Y_{t-1}, \tag{3}$$

mientras que, para un número general d de diferenciaciones, se define la serie transformada como

$$W_t = (1 - B)^d Y_t. \tag{4}$$

El objetivo de esta transformación es obtener una serie cuya estructura temporal pueda ser modelada mediante un proceso ARMA. El número de diferenciaciones d será determinado a partir del análisis de estacionariedad de la serie, evitando aplicar diferenciaciones innecesarias.

Una vez definida la serie W_t, se postula que esta puede ser representada mediante un modelo ARMA(p, q). En notación de operadores, el modelo se expresa como

$$\phi(B)W_t = c + \theta(B)\varepsilon_t, \tag{5}$$

donde c es una constante, ε_t representa el término de error en el instante t, y los polinomios autorregresivo y de medias móviles están definidos, respectivamente, como

$$\phi(B) = 1 - \phi_1 B - \phi_2 B^2 - \cdots - \phi_p B^p \tag{6}$$

y

$$\theta(B) = 1 + \theta_1 B + \theta_2 B^2 + \cdots + \theta_q B^q. \tag{7}$$

Los parámetros ϕ_i corresponden a los coeficientes de la componente autorregresiva y determinan la relación entre el valor actual de la serie diferenciada y sus valores pasados. Por su parte, los parámetros θ_j corresponden a los coeficientes de la componente de medias móviles y permiten incorporar al modelo información asociada con errores pasados. El término ε_t se supone de media cero y varianza constante, es decir,

$$E(\varepsilon_t) = 0, \qquad Var(\varepsilon_t) = \sigma^2. \tag{8}$$

Al sustituir la definición de W_t, se obtiene la representación general del modelo ARIMA (p, d, q):

$$\phi(B)(1 - B)^d Y_t = c + \theta(B)\varepsilon_t \tag{9}$$

Esta ecuación constituye el postulado matemático utilizado para representar la dinámica temporal de la serie de precios. La expresión muestra explícitamente los tres componentes del modelo: $\phi(B)$ corresponde a la componente autorregresiva (AR), $(1 - B)^d$ representa la componente integrada (I), y $\theta(B)$ corresponde a la componente de medias móviles (MA).

2.1.1. Forma desarrollada del modelo

La ecuación puede desarrollarse utilizando la definición del operador de rezago. Para la componente autorregresiva se tiene

$$\phi(B)W_t = \left(1 - \phi_1 B - \phi_2 B^2 - ... - \phi_p B^p\right) W_t = W_t - \phi_1 W_{t-1} - \phi_2 W_{t-2} - ... - \phi_p W_{t-p}. \quad (10)$$

De manera análoga, para la componente de medias móviles,

$$\theta(B)\varepsilon_t = \left(1 + \theta_1 B + \theta_2 B^2 + ... + \theta_q B^q\right) \varepsilon_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + ... + \theta_q \varepsilon_{t-q}. \quad (11)$$

Por consiguiente, la ecuación puede escribirse como

$$W_t - \sum_{i=1}^{p} \phi_i W_{t-i} = c + \varepsilon_t + \sum_{j=1}^{q} \theta_j \varepsilon_{t-j}, \quad (12)$$

o, equivalentemente,

$$W_t = c + \sum_{i=1}^{p} \phi_i W_{t-i} + \varepsilon_t + \sum_{j=1}^{q} \theta_j \varepsilon_{t-j} \quad (13)$$

Esta representación permite interpretar directamente el modelo. La componente autorregresiva utiliza valores pasados de W_t, mientras que la componente de medias móviles incorpora errores pasados del modelo.

2.1.2. Estimación de los parámetros

Una vez definida la estructura ARIMA(p, d, q), los parámetros del modelo no se conocen a priori, sino que se estiman utilizando la información contenida en la serie histórica. En particular, se consideran como parámetros desconocidos la constante c, los coeficientes autorregresivos $\phi_1, \ldots, \phi_p$, los coeficientes de medias móviles $\theta_1, \ldots, \theta_q$ y la varianza del término de error σ^2.

Sea el vector de parámetros

$$\eta = (c, \phi_1, \ldots, \phi_p, \theta_1, \ldots, \theta_q, \sigma^2). \quad (14)$$

La estimación de estos parámetros se realizará mediante el método de máxima verosimilitud.

Posterior a la estimación, resultará importante evaluar la significancia estadística de cada parámetro obtenido, con el propósito de garantizar la robustez estadistica y evitar la sobreparametrización del modelo. Para lograr esto, se realizará a cada coeficiente estimado una prueba de significancia donde la hipótesis nula establece que el parámetro no tiene efecto predictivo (es decir, es estadísticamente igual a cero):

$$H_0 : \eta_k = 0 \quad \text{vs} \quad H_1 : \eta_k \neq 0 \quad (15)$$

donde η_k hace referencia a cualquiera de los coeficientes autorregresivos (ϕ_i) o de medias móviles (θ_j) estimados.

La evaluación de esta hipótesis se fundamenta en el estadístico de prueba z y su respectivo valor-p (p-value). Considerando un nivel de significancia estándar del 5 % ($\alpha = 0{,}05$), la regla de decisión dicta el rechazo de la hipótesis nula si el valor-$p < 0{,}05$. Bajo este resultado, se concluye que el parámetro analizado aporta información relevante y significativa a la predicción de la variable.

Por el contrario, si el valor-$p \geq 0{,}05$, no existe evidencia estadística suficiente para rechazar H_0, indicando que el coeficiente no aporta un poder explicativo real. La elección de un nivel de significancia del 5 % ($\alpha = 0,05$, equivalente a un 95 % de confianza) guarda congruencia directa con la gestión de riesgo en finanzas, específicamente con el uso del Value at Risk (VaR). En el análisis de activos financieros, el VaR al 95 % de confianza se utiliza para estimar la pérdida máxima esperada de un activo o portafolio en condiciones normales, asumiendo que solo un 5 % de las veces (en escenarios de cola o eventos extremos) se superará dicho límite. Al exigir este mismo umbral del 5 % en las pruebas de hipótesis de los coeficientes ARIMA, se alinea la rigurosidad estadística del modelo con los estándares del mercado, se garantiza un 95 % de certeza que los parámetros capturan relaciones reales de los precios y no ruido aleatorio, respaldando la significancia estadística del modelo.

2.2. Reglas de trading

Las reglas de trading se encargan de convertir los pronósticos de precio del modelo ARIMA en decisiones claras de compra, venta o permanencia. En cada período, el sistema calcula la diferencia entre el precio que el modelo proyecta para el siguiente periodo y el último precio de cierre real. Para evitar entrar al mercado por cambios muy pequeños o por simple ruido de los datos, se define un margen mínimo que esta diferencia debe superar para validar una operación.

A partir de esta comparación, se aplicarán las siguientes reglas:

- **Señal de compra:** Se activa cuando el precio pronosticado es mayor que el precio actual y la diferencia supera el margen mínimo establecido.
- **Señal de venta:** Se activa cuando el precio pronosticado es menor que el precio actual y la diferencia supera dicho margen.
- **Señal neutral:** Ocurre cuando la diferencia no alcanza el margen mínimo, lo que indica que no hay una tendencia clara y se decide mantener la posición o cerrar la operación según la estrategia.

Además, el sistema incluye reglas para gestionar el riesgo, definiendo el tamaño de la inversión y fijando límites automáticos para pérdidas y ganancias, lo que asegura que las decisiones se ejecuten de manera automática y sin intervención manual.

2.3. Backtesting

El proceso de backtesting se realizará en cTrader, una plataforma de simulación y ejecución de operaciones financieras reconocida por su precisión en el procesamiento de datos

históricos y la ejecución de órdenes, implementando el algoritmo mediante el lenguaje de programación C#. La prueba se realizará sobre los activos seleccionados para la evaluación de la estrategia (Apple, NASDAQ 100, Dow Jones y S&P 500) aplicando las reglas de trading explicadas en la sección 2.3 de manera uniforme y sin realizar ajustes manuales durante el período, el cual se establecerá desde el 05-10-2021 hasta el 05-10-2026 y con un capital inicial de 10.000 EU. Además, durante el *backtesting* se van a probar varias combinaciones con los límites máximos de los parámetros p y q. Es importante resaltar que estos parámetros no se quedan fijos todo el tiempo, sino que se van actualizando sobre la marcha según cómo le vaya yendo a la estrategia (si va ganando o perdiendo), adaptándose a los resultados que vaya arrojando el mercado y teniendo en cuenta la significancia estadística del modelo. Para evaluar el desempeño financiero de la estrategia en cada activo, se analizará el beneficio neto y la rentabilidad, los cuales miden la ganancia monetaria total y el porcentaje de crecimiento obtenido en relación con el capital inicial; así como el máximo drawdown (máximo retroceso), que cuantifica la mayor caída acumulada entre un pico y un valle en la cuenta para medir la exposición al riesgo. De esta manera, el análisis de estas métricas permitirá estudiar de forma directa la relación entre el retorno generado y la estabilidad de la estrategia en cada mercado evaluado.

2.4. Suposiciones y limitaciones

La metodología propuesta estará basada en el supuesto de que la información histórica de los precios contiene una estructura temporal que puede ser identificada y utilizada parcialmente para generar pronósticos. Sin embargo, este supuesto no implica que los precios futuros puedan ser determinados de manera exacta a partir de los valores históricos.

Una de las principales limitaciones será que el modelo ARIMA se basa en la estructura temporal de la serie analizada y no incorporará inicialmente variables externas o información adicional relacionada con el mercado. Por esta razón, factores como noticias económicas, cambios en las condiciones del mercado, variables macroeconómicas o acontecimientos específicos de las empresas no serán incluidos directamente en el modelo.

También se tendrá en cuenta que las series financieras pueden presentar comportamientos no estacionarios, cambios estructurales, volatilidad y ruido, características que pueden reducir la capacidad de los modelos de series de tiempo para generar pronósticos precisos. Estas características constituyen una limitación importante debido a que las relaciones identificadas en un periodo histórico pueden no mantenerse durante periodos posteriores. Finalmente, los resultados del backtesting estarán condicionados por el periodo histórico seleccionado, la calidad de los datos disponibles y las reglas específicas definidas para la estrategia. Asimismo, una limitación importante es la disponibilidad de información en la plataforma cTrader, ya que los datos históricos no estan completos para la totalidad de los activos evaluados inicialmente, por esta razón, solo se seleccionaran cuatro de ellos (Apple, NASDAQ 100, Dow Jones y S&P 500) para la fase de prueba, mientras que los activos restantes se emplearán exclusivamente para el entrenamiento de los modelos.

3. Resultados

3.1. Series de tiempo originales

Antes de ajustar los modelos ARIMA, se realizaron pruebas estadísticas para evaluar las propiedades de las series de tiempo consideradas. La Tabla 1 presenta los resultados de la prueba de Dickey-Fuller Aumentada (ADF), utilizada para verificar la estacionariedad de las series. Posteriormente, la Tabla 2 muestra los resultados de la prueba de Ljung-Box aplicada a las series diferenciadas, con el objetivo de identificar la presencia de autocorrelación significativa en los rezagos. En conjunto, estas pruebas permiten justificar la necesidad de diferenciar las series y corroborar la existencia de estructura temporal que puede ser modelada mediante enfoques ARIMA.

Cuadro 1: Prueba de estacionariedad ADF para los activos analizados

Activo	Estadístico ADF	Valor-p	Estacionaria (5 %)
AAPL	-0.108860	0.948549	Falso
NVDA	-0.012188	0.957512	Falso
MSFT	-0.062665	0.953033	Falso
GOOGL	-0.129311	0.946440	Falso
SPX	-0.588280	0.873608	Falso
NDX	-0.429337	0.905084	Falso
CBNK	-2.583946	0.096361	Falso
NBI	-1.724225	0.418676	Falso
AMZN	-1.409805	0.577566	Falso
DJI	-1.322117	0.618994	Falso

Cuadro 2: Resultados de la prueba de Ljung-Box sobre las series diferenciadas

Activo	d aplicado	Valor-p (Ljung-Box, rezago 10)	¿Rezagos con comportamiento?
AAPL	1	0.0002	Sí
NVDA	1	0.0000	Sí
MSFT	1	0.0000	Sí
GOOGL	1	0.0005	Sí
SPX	1	0.0000	Sí
NDX	1	0.0000	Sí
CBNK	1	0.0000	Sí
NBI	1	0.0011	Sí
AMZN	1	0.0270	Sí
DJI	1	0.0000	Sí

3.2. Significancia estadistica - Modelos ARIMA

Las Tablas mostradas a continuación presentan los resultados de estimación de los distintos modelos ARIMA evaluados. En cada tabla se reportan los coeficientes de los términos autorregresivos (AR) y de medias móviles (MA), junto con sus errores estándar, estadísticos z, valores-p e intervalos de confianza al 95 %. La inclusión de estas tablas en el informe permite analizar la significancia estadística de los parámetros estimados y verificar que los componentes del modelo contribuyen de manera relevante a la representación de la serie temporal. En particular, los valores-p inferiores a 0.05 indican evidencia suficiente para considerar significativos los coeficientes correspondientes, lo que respalda la validez de la estructura ARIMA seleccionada.

Cuadro 3: Apple

Parámetro	Coef.	Std. Err.	z	P> $\|z\|$	IC 2.5 %	IC 97.5 %
ar.L1	0.5106	0.002	261.776	0.000	0.507	0.514
ar.L2	-0.9981	0.002	-547.301	0.000	-1.002	-0.995
ma.L1	-0.5160	0.002	-217.115	0.000	-0.521	-0.511
ma.L2	0.9966	0.003	397.766	0.000	0.992	1.002
sigma^2	3.9247	0.059	66.112	0.000	3.808	4.041

Cuadro 4: Nvidia

Parámetro	Coef.	Std. Err.	z	P> $\|z\|$	IC 2.5 %	IC 97.5 %
ar.L1	-1.2802	0.033	-39.313	0.000	-1.344	-1.216
ar.L2	0.4027	0.051	7.847	0.000	0.302	0.503
ar.L3	1.0797	0.038	28.398	0.000	1.005	1.154
ar.L4	0.3936	0.053	7.441	0.000	0.290	0.497
ar.L5	0.0975	0.032	3.068	0.002	0.035	0.160
ma.L1	1.2030	0.031	39.206	0.000	1.143	1.263
ma.L2	-0.6070	0.049	-12.423	0.000	-0.703	-0.511
ma.L3	-1.1449	0.036	-32.002	0.000	-1.215	-1.075
ma.L4	-0.1084	0.052	-2.078	0.038	-0.211	-0.006
ma.L5	0.1702	0.029	5.789	0.000	0.113	0.228
sigma^2	0.9554	0.007	129.882	0.000	0.941	0.970

Cuadro 5: Microsoft

Parámetro	Coef.	Std. Err.	z	P> |z|	IC 2.5 %	IC 97.5 %
ar.L1	0.5891	0.014	41.830	0.000	0.561	0.617
ar.L2	-0.9669	0.015	-62.479	0.000	-0.997	-0.937
ar.L3	-0.0670	0.015	-4.519	0.000	-0.096	-0.038
ar.L4	-0.0341	0.014	-2.351	0.019	-0.062	-0.006
ma.L1	-0.6894	0.004	-173.741	0.000	-0.697	-0.682
ma.L2	0.9941	0.004	248.606	0.000	0.986	1.002
sigma^2	12.9170	0.225	57.459	0.000	12.476	13.358

Cuadro 6: Google

Parámetro	Coef.	Std. Err.	z	P> |z|	IC 2.5 %	IC 97.5 %
ar.L1	0.6826	0.130	5.262	0.000	0.428	0.937
ma.L1	-0.7267	0.123	-5.924	0.000	-0.967	-0.486
sigma^2	2.8741	0.036	80.164	0.000	2.804	2.944

Cuadro 7: S&P500

Parámetro	Coef.	Std. Err.	z	P> |z|	IC 2.5 %	IC 97.5 %
ar.L1	-1.6960	0.029	-59.467	0.000	-1.752	-1.640
ar.L2	-0.8488	0.027	-31.201	0.000	-0.902	-0.795
ma.L1	1.6425	0.031	52.168	0.000	1.581	1.704
ma.L2	0.7723	0.035	21.830	0.000	0.703	0.842
ma.L3	-0.0632	0.024	-2.621	0.009	-0.110	-0.016
ma.L4	-0.0628	0.014	-4.615	0.000	-0.089	-0.036
sigma^2	1369.9714	22.698	60.357	0.000	1325.484	1414.459

Cuadro 8: Nasdaq-100

Parámetro	Coef.	Std. Err.	z	P> |z|	IC 2.5 %	IC 97.5 %
ar.L1	-0.7305	0.074	-9.935	0.000	-0.875	-0.586
ar.L2	0.6883	0.114	6.064	0.000	0.466	0.911
ar.L3	0.7693	0.077	9.926	0.000	0.617	0.921
ar.L4	0.0576	0.020	2.909	0.004	0.019	0.096
ar.L5	0.0785	0.016	4.935	0.000	0.047	0.110
ma.L1	0.6628	0.072	9.155	0.000	0.521	0.805
ma.L2	-0.7456	0.107	-6.990	0.000	-0.955	-0.537
ma.L3	-0.7774	0.069	-11.308	0.000	-0.912	-0.643
sigma^2	2.302e+04	433.385	53.112	0.000	2.22e+04	2.39e+04

Cuadro 9: Nasdaq Bank Index

Parámetro	Coef.	Std. Err.	z	P> |z|	IC 2.5 %	IC 97.5 %
ar.L1	-1.7284	0.029	-58.805	0.000	-1.786	-1.671
ar.L2	-0.9072	0.030	-29.910	0.000	-0.967	-0.848
ma.L1	1.6816	0.035	48.446	0.000	1.614	1.750
ma.L2	0.8621	0.036	24.022	0.000	0.792	0.932
$sigma^2$	3744.4558	66.924	55.950	0.000	3613.286	3875.625

Cuadro 10: Nasdaq Biotechnology Index

Parámetro	Coef.	Std. Err.	z	P> |z|	IC 2.5 %	IC 97.5 %
ar.L1	-1.7574	0.041	-42.504	0.000	-1.838	-1.676
ar.L2	-0.8881	0.040	-22.215	0.000	-0.966	-0.810
ma.L1	1.7126	0.047	36.222	0.000	1.620	1.805
ma.L2	0.8414	0.046	18.344	0.000	0.752	0.931
$sigma^2$	3118.4747	68.351	45.624	0.000	2984.509	3252.440

Cuadro 11: Amazon

Parámetro	Coef.	Std. Err.	z	P> |z|	IC 2.5 %	IC 97.5 %
ar.L1	-1.5965	0.035	-45.908	0.000	-1.665	-1.528
ar.L2	-0.9681	0.039	-24.972	0.000	-1.044	-0.892
ar.L3	-0.0843	0.030	-2.802	0.005	-0.143	-0.025
ar.L4	-0.0347	0.017	-2.020	0.043	-0.068	-0.001
ma.L1	1.5837	0.033	48.092	0.000	1.519	1.648
ma.L2	0.9207	0.031	30.101	0.000	0.861	0.981
$sigma^2$	5.5391	0.077	71.878	0.000	5.388	5.690

Cuadro 12: Dow Jones Industrial Average

Parámetro	Coef.	Std. Err.	z	P> |z|	IC 2.5 %	IC 97.5 %
ar.L1	-1.6393	0.035	-46.456	0.000	-1.708	-1.570
ar.L2	-0.7256	0.044	-16.472	0.000	-0.812	-0.639
ar.L3	0.0613	0.015	4.124	0.000	0.032	0.090
ma.L1	1.5866	0.033	47.840	0.000	1.522	1.652
ma.L2	0.7071	0.031	22.683	0.000	0.646	0.768
$sigma^2$	8.324e+04	1236.605	67.313	0.000	8.08e+04	8.57e+04

3.3. Predicción de Precios - Modelos ARIMA

En la tabla mostrada a continuación se observan los resultados obtenidos tras ajustar el modelo ARIMA para cada uno de los activos analizados. En esta, se especifica la combinación óptima de parámetros (p, d, q) seleccionada para cada caso, junto con las métricas estadísticas empleadas para medir el margen de error de los pronósticos, el RMSE (raíz del error cuadrático medio), el MAE (error absoluto medio) y el MAPE (error porcentual absoluto medio). Entre menor sea el valor de estas métricas, mayor es la precisión del modelo al predecir los precios reales.

captionMétricas de validación para los pronósticos ARIMA por activo

Activo	**Modelo**	**RMSE**	**MAE**	**MAPE (%)**
APPLE	ARIMA(2,1,2)	4.206763	2.856010	1.149381
NVIDIA	ARIMA(5,1,5)	4.736998	3.552502	2.227894
MICROSOFT	ARIMA(4,1,2)	7.502682	5.036474	1.155357
GOOGLE	ARIMA(1,1,1)	5.088378	3.438050	1.383815
S&P500	ARIMA(2,1,4)	59.761063	42.237591	0.665251
NASDAQ-100	ARIMA(5,1,3)	308.542527	221.777643	0.939580
NASDAQ BANK INDEX	ARIMA(2,1,2)	66.202808	45.782945	1.012173
NASDAQ BIOTECHNOLOGY INDEX	ARIMA(2,1,2)	71.287531	52.599671	1.014026
AMAZON	ARIMA(4,1,2)	4.546093	3.228162	1.462559
DOW JONES INDUSTRIAL AVERAGE	ARIMA(3,1,2)	403.130308	292.601879	0.641430

3.4. Resultados Variación de Parámetros - Backtesting

Para evaluar el comportamiento de la estrategia ante las distintas combinaciones de los parámetros máximos de p y q, se generaron tres gráficas para cada activo. Primero, el mapa de calor de rentabilidad muestra el porcentaje de rentabilidad entre más claro sea el color, mayor rentabilidad obtenida, mientras que los tonos oscuros indican perdidas o rendimientos negativos. Segundo, el mapa de calor del máximo drawdown mide el riesgo y las caídas de los precios, los tonos más claros señalan las configuraciones que sufrieron las caidas más drásticas y peligrosas, y los oscuros representan un menor riesgo. Por último, la superficie 3D del beneficio neto grafica el dinero ganado o perdido en tres dimensiones, en este los picos más altos y claros representan las zonas de mayor ganancia, facilitando identificar visualmente la mejor combinación de parámetros para el modelo.

3.4.1. Nasdaq-100

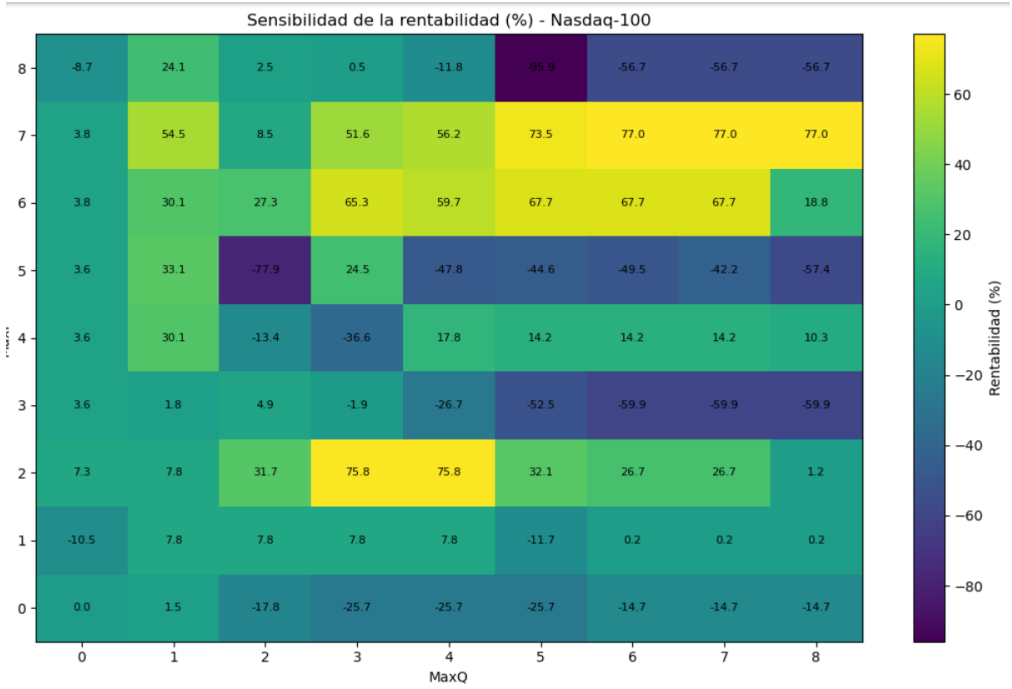


Figura 1: Sensibilidad de la rentabilidad - Nasdaq-100

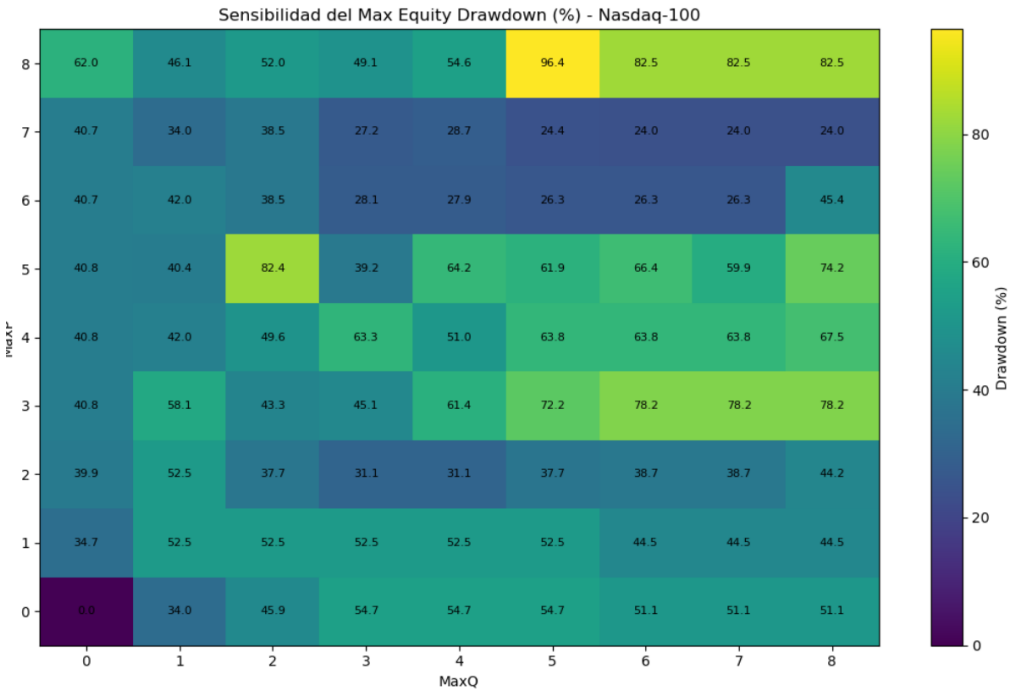


Figura 2: Sensibilidad maximo drawdown - Nasdaq-100

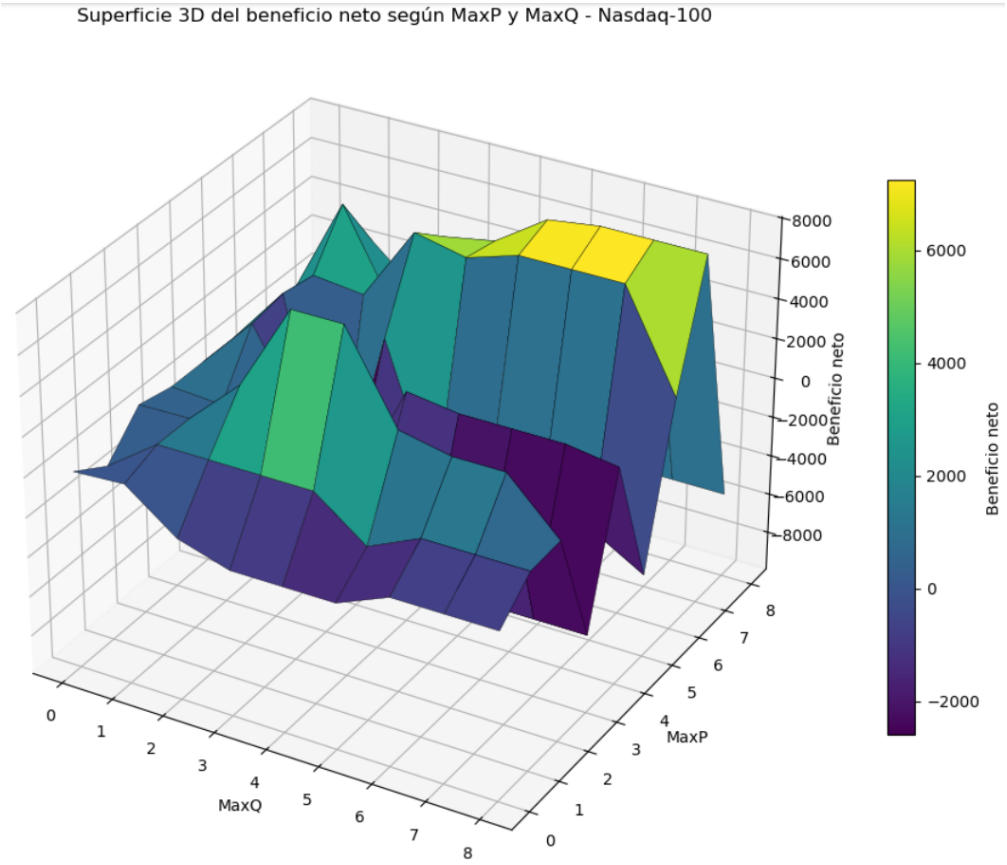


Figura 3: Superficie 3D del beneficio neto - Nasdaq-100

3.4.2. Dow Jones Industrial Average

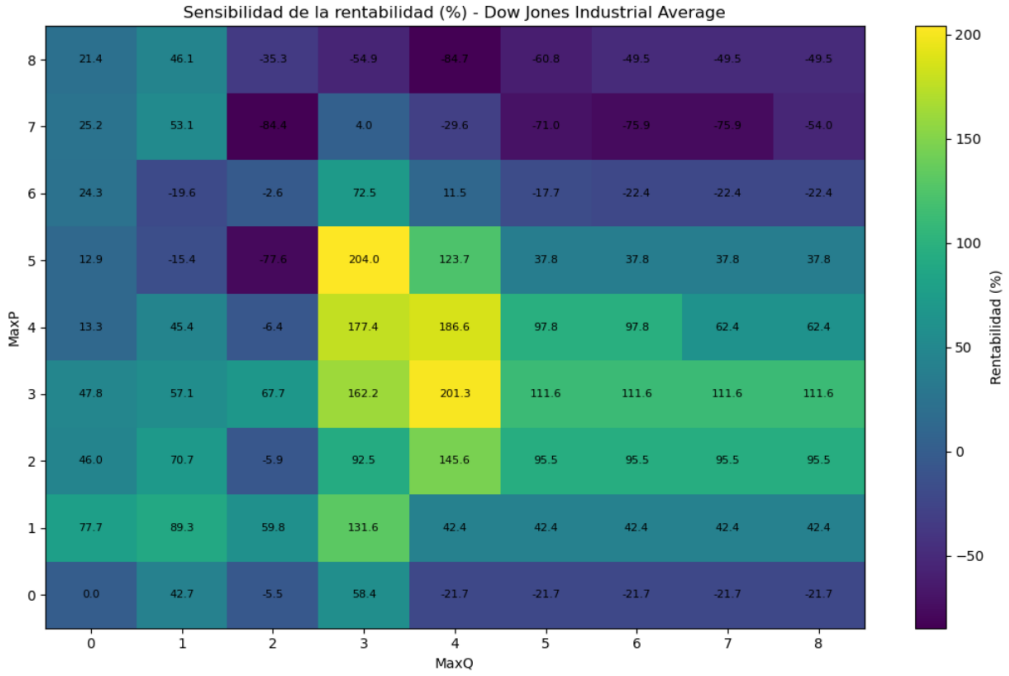


Figura 4: Sensibilidad de la rentabilidad - Dow Jones Industrial Average

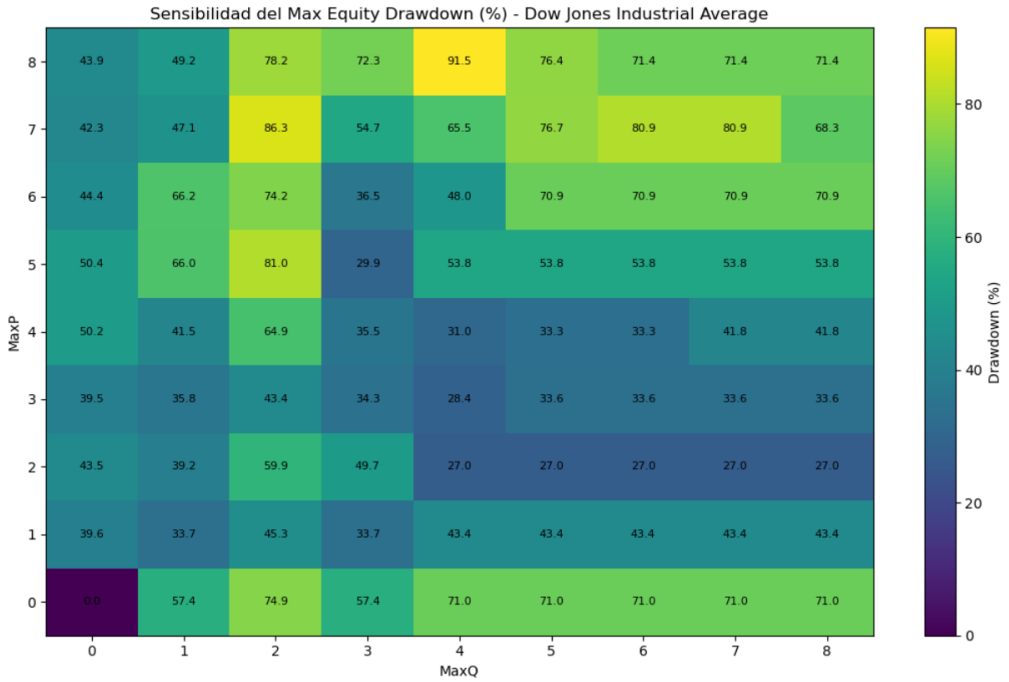


Figura 5: Sensibilidad maximo drawdown - Dow Jones Industrial Average

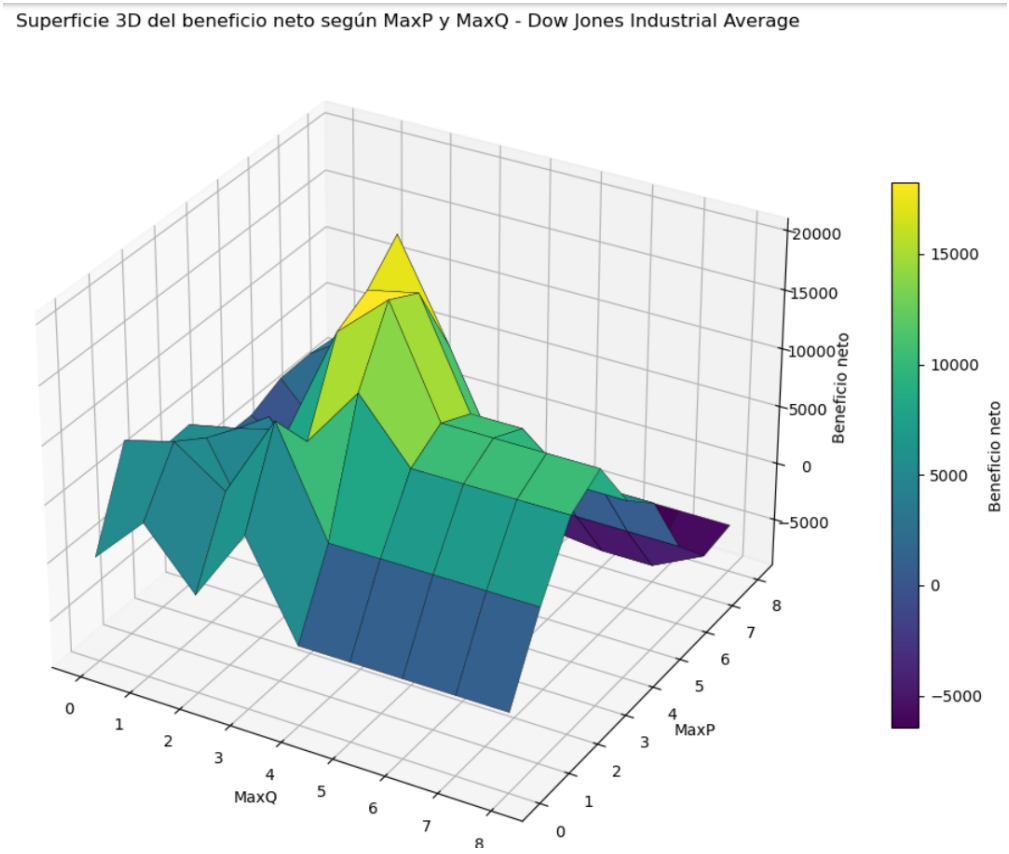


Figura 6: Superficie 3D del beneficio neto - Dow Jones Industrial Average

3.4.3. S&P 500

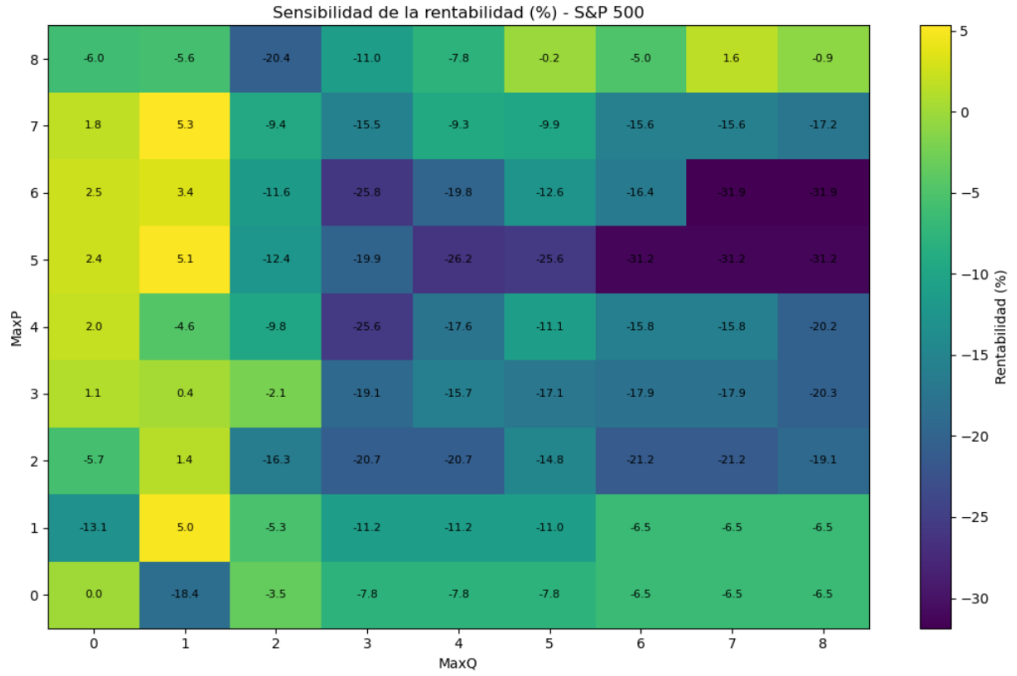


Figura 7: Sensibilidad de la rentabilidad - S&P 500

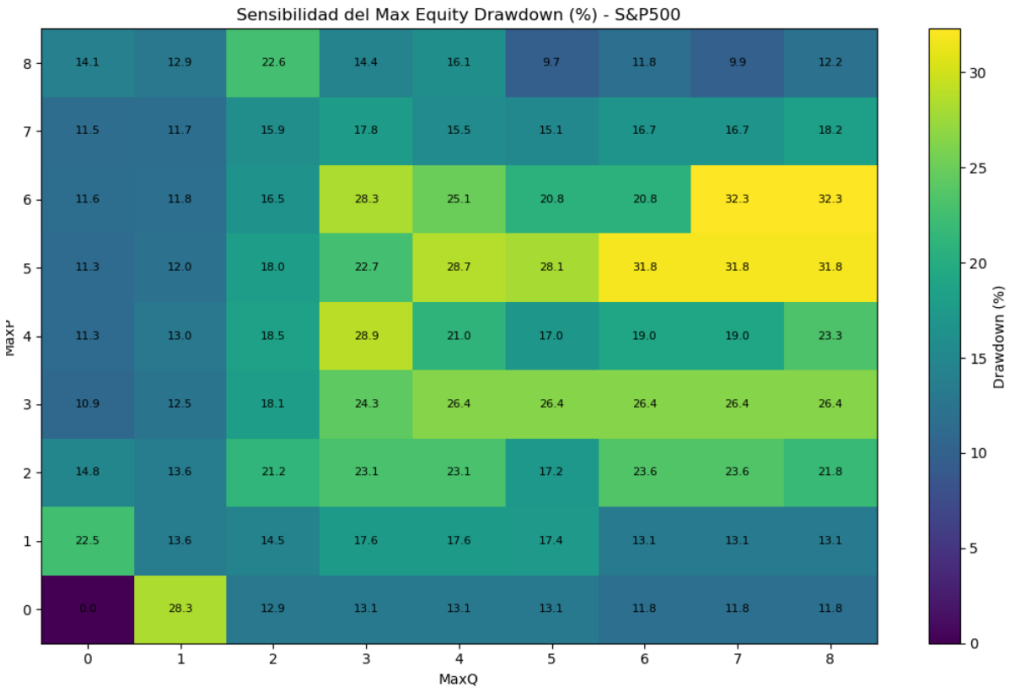


Figura 8: Sensibilidad maximo drawdown - S&P 500

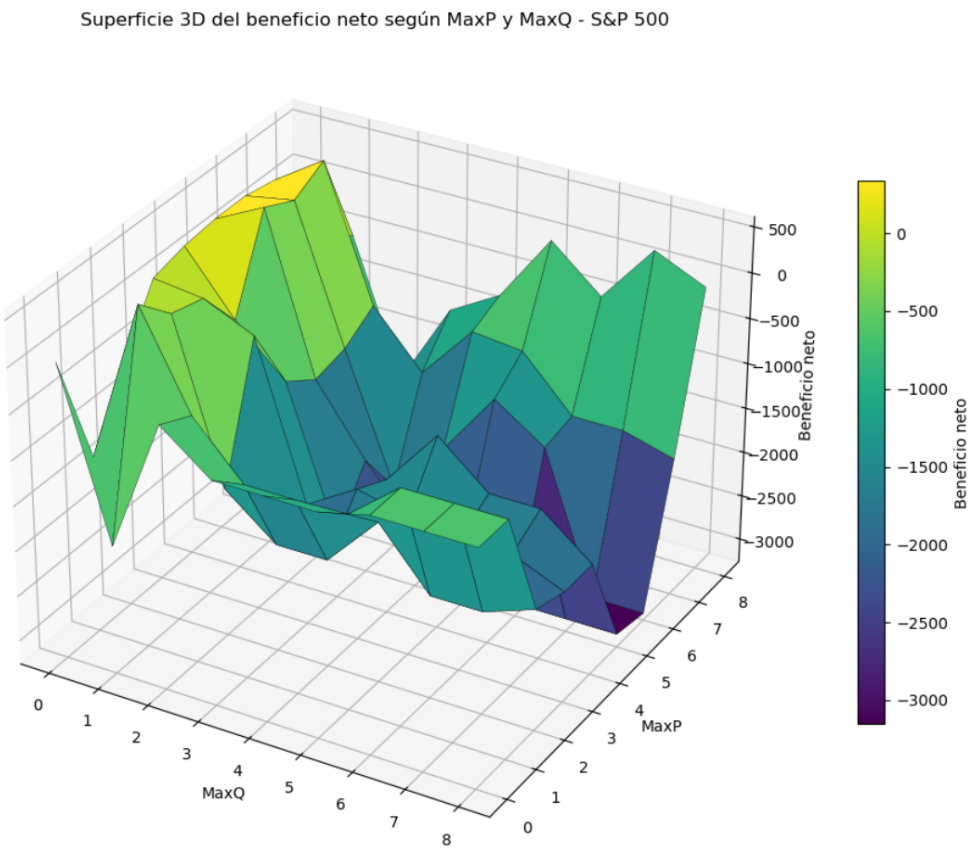


Figura 9: Superficie 3D del beneficio neto - S&P 500

3.4.4. Apple

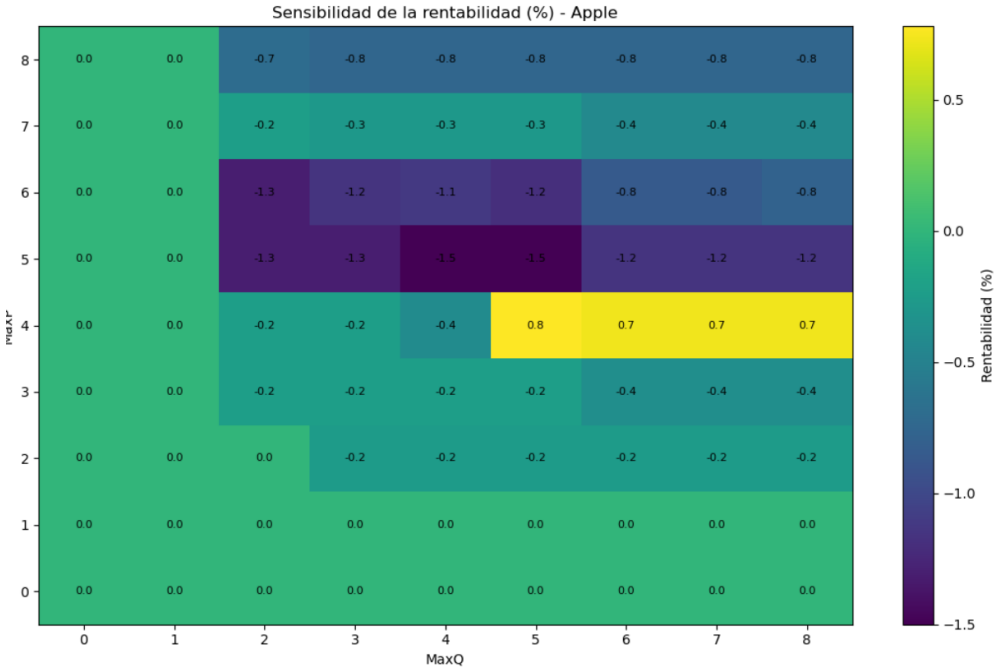


Figura 10: Sensibilidad de la rentabilidad - Apple

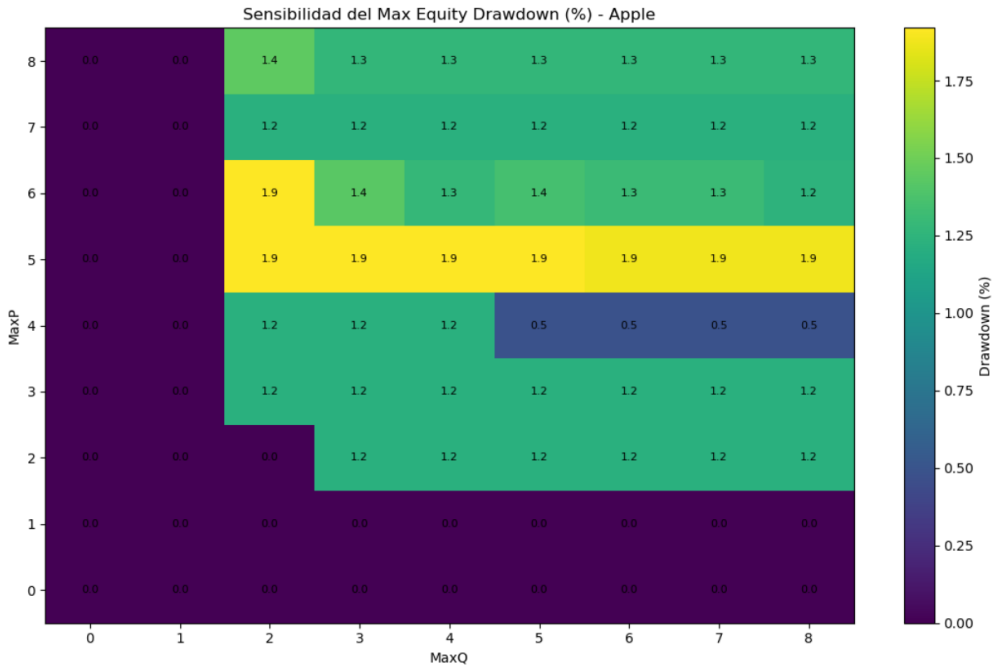


Figura 11: Sensibilidad maximo drawdown - Apple

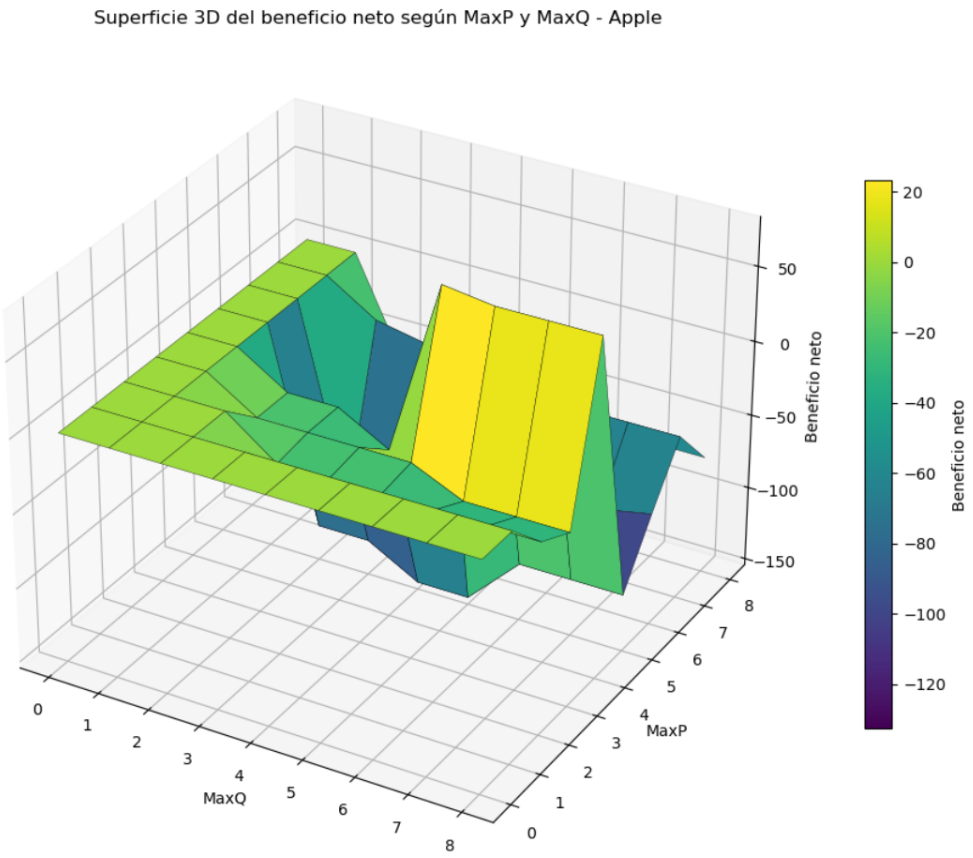


Figura 12: Superficie 3D del beneficio neto - Apple

3.5. Resultados Mejor Combinación De Parámetros - Backtesting

A continuación se presentan los resultados obtenidos al aplicar la estrategia de trading utilizando la mejor combinación de parámetros seleccionada para cada activo. Las gráficas muestran el comportamiento financiero a lo largo del periodo de evaluación, dividido en dos partes, por un lado, la evolución de la rentabilidad que refleja el crecimiento porcentual acumulado de las operaciones y por otro, la curva de capital, que detalla de forma monetaria el saldo de la cuenta y permite visualizar de manera directa los periodos de ganancias y las caídas o retrocesos experimentados durante la ejecución del modelo.

3.5.1. Nasdaq-100 (Máximo p = 7, Máximo d = 2, Máximo q = 6)

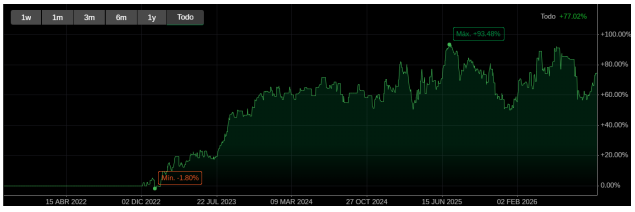


Figura 13: Curva de rendimiento - Nasdaq - 100.

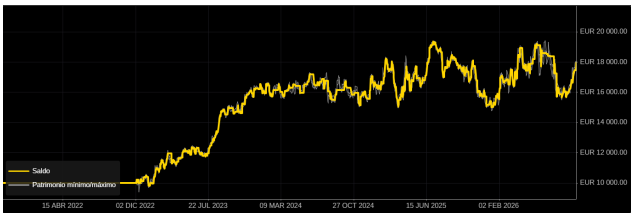


Figura 14: Evolución del capital - Nasdaq - 100

3.5.2. Dow Jones Industrial Average (Máximo p = 5, Máximo d = 2, Máximo q = 3)



Figura 15: Curva de rendimiento - Dow Jones Industrial Average.



Figura 16: Evolución del capital - Dow Jones Industrial Average.

3.5.3. S&P 500 (Máximo p = 7, Máximo d = 2, Máximo q = 1)

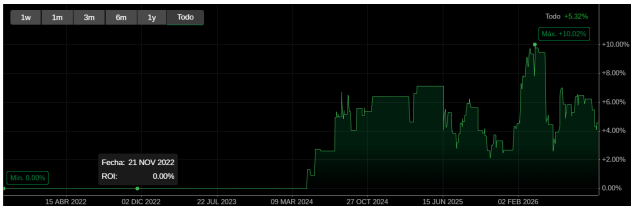


Figura 17: Curva de rendimiento - S&P 500

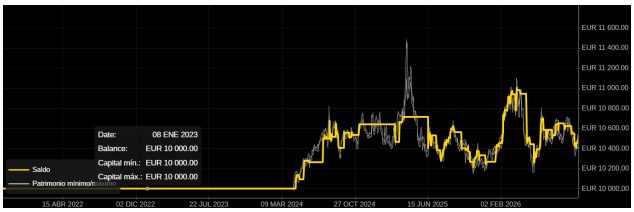


Figura 18: Evolución del capital - S&P 500

3.5.4. Apple (Máximo p = 4, Máximo d = 2, Máximo q = 5)

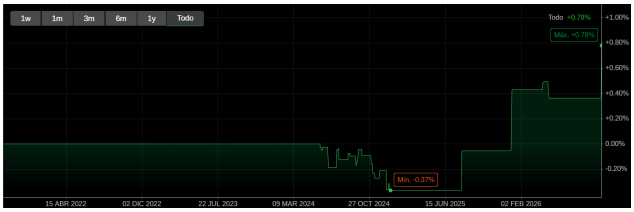


Figura 19: Curva de rendimiento - Apple

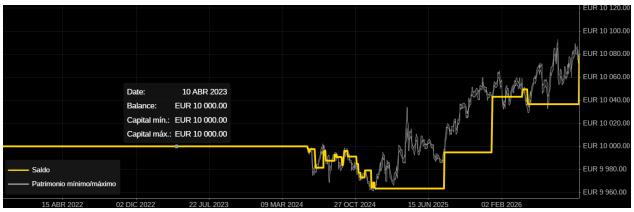


Figura 20: Evolución del capital - Apple

4. Discusión

Referencias

[1] R. Kalra et al., "An efficient hybrid approach for forecasting real-time stock market indices," *Journal of King Saud University - Computer and Information Sciences*, vol. 36, no. 8, p. 102180, 2024. DOI: https://doi.org/10.1016/j.jksuci.2024.102180.

[2] S. Murray, Y. Xia, and H. Xiao, "Charting by machines," *Journal of Financial Economics*, vol. 153, p. 103791, 2024. DOI: https://doi.org/10.1016/j.jfineco.2024.103791.

[3] A. M. Awajan, F. M. AL Faqih, M. T. Ismail, B. N. Al-Hasanat, M. Z. Swalmeh, and S. Al Wadi, "A new hybrid approach for forecasting of daily stock market time series data," *Electronic Journal of Applied Statistical Analysis*, vol. 17, no. 1, pp. 172–190, 2024. URL: https://ese-journals.unisalento.it/index.php/ejasa/article/view/27483.

[4] G. E. P. Box and G. M. Jenkins, *Time Series Analysis: Forecasting and Control*. San Francisco: Holden-Day, 1976.

[5] F. Dakalbab, M. A. Talib, Q. Nassir, and T. Ishak, "Artificial intelligence techniques in financial trading: A systematic literature review," *Journal of King Saud University - Computer and Information Sciences*, vol. 36, p. 102015, 2024. DOI: https://doi.org/10.1016/j.jksuci.2024.102015.

[6] K. Olorunnimbe and H. Viktor, "Deep learning in the stock market—a systematic survey of practice, backtesting, and applications," *Artificial Intelligence Review*, vol. 56, no. 3, pp. 2057–2109, 2023. DOI: https://doi.org/10.1007/s10462-022-10226-0.

[7] A. Väistö, "Comparing SMA and ARIMA on Bitcoin value prediction," Bachelor's thesis, Haaga-Helia University of Applied Sciences, Theseus Repository, 2021. URL: https://www.theseus.fi/handle/10024/920698.

[8] S. Park and H. Kim, "The way to invest: Trading strategies based on ARIMA and investor personality," *Journal of Behavioral and Experimental Finance*, vol. 28, p. 100401, 2020. URL: https://www.mdpi.com/2073-8994/14/11/2292.

[9] R. Ślepaczuk, P. Zakrzewski, and T. Sakowski, "Applying Hybrid ARIMA-SGARCH in Algorithmic Investment Strategies on S&P 500 Index," *Entropy*, vol. 24, no. 2, p. 158, 2022. DOI: https://doi.org/10.3390/e24020158.